

理想同学·具身智能体

理想汽车 理想同学负责人
江会星

大家好，我是江会星。今天分享的题目是——「理想同学：具身智能体」。

各位可能对理想同学不陌生。在理想汽车里喊一声"理想同学"，它都能事事回应。它是理想汽车的智能助手。今天不讲它已经做了什么，而是讲它正在成为什么。一个全新的阶段，一个从"听得见"到"看得懂、动得了"的具身智能体。希望接下来的分享，对各位有所启发。



理想同学的自研之路，始于2022年。这五年，恰好也是大模型到智能体飞速跨越的五年。

1 2022年，ChatGPT 还没出现。行业主流是分类模型 BERT。但我们看到了 T5 这种 encoder-decoder 架构强大的生成能力，从一开始就选择用 T5，端到端地生成理想同学的理解能力。那时候，GPT 还没火，行业里敢用生成式架构来做对话助手的团队，很少。

2 2023年初，ChatGPT 引爆行业。我们第一时间立项自研 MindGPT，年底就把它推上线了。是行业第一家做到这点的车企——不是 demo，是真正交付给用户。

3 2024年，把 MindGPT 的能力往外延伸。两件事：通用的 Function Call，让模型能调用海量工具；补齐记忆能力，让理想同学越用越懂你。有了这两样，它才从一个“会说话的模型”变成了一个“能办事的助手”。

4 2025年，智能体元年。行业在狂奔，但谈不上成熟。我们的架构从单智能体升级到多智能体——理想同学做主智能体，连接一群子智能体，核心是建了一套连接 AI 服务生态的能力。

5 今年初，OpenClaw 爆火。它标志着一个新时代：个人智能体。三个标志性变化——智能体跑在终端、智能体和模型解耦、按 tokens 计费。理想同学现在的阶段，就是这个范式。



这页是理想同学智能体 2.0 的架构全景。图的左边是大脑，右边是手脚。

0 左边是理想同学的主智能体。以MindGPT大模型为核心引擎，全信息记忆是它的经验库。它主要干三件事：规划推理、任务编排、调度工具。用户的一个真实需求进来，它负责从头到尾编排执行，用户只看到一个结果，背后是复杂的推理和调度。

0 右边是三种工具连接能力，打通整个服务生态。

1 CUA Cockpit Using Agent。很多平台不提供 API，接口调不了怎么办？我们用大模型的视觉能力，直接看屏幕，模拟人的点击、输入、滑动、扫码。不需要对方配合，什么界面都能打通。

2 A2A—连接内部子智能体和第三方智能体。主智能体拿到其它智能体的能力描述，自动分发任务、回收结果、结构化呈现。用户只看到一个答案，背后已经是多个智能体在协同作战。

3 MCP——这是工具底座。第三方应用、车控指令，我们全部封装成标准 MCP 协议接口。目的就一个：让 MindGPT大模型 能更好地统一理解，统一调用。



来看两个CUA 和 A2A 落地真实案例，

- 1 左边是 CUA 的玩法——停车缴费。车开到停车场，车身摄像头一扫，缴费二维码就识别到了。拉起支付宝小程序之后，CUA 直接读屏幕，模拟人的操作，把缴费流程走完。整个过程中，小程序没有提供任何 API，但 CUA 照样能搞定。这个我们在2025年首次推出的，不只是停车缴费，通过这种方式来操作支付宝小程序，可以完成点餐、交生活费等等；
- 2 右边是 A2A 的方式，我们先看下视频。
- 3 上面是加油支付，下面是买电影票。这里不再是模拟屏幕操作，而是通过 A2A 直接调用蚂蚁的阿宝 Agent，任务端到端执行。
- 4 从 CUA 到 A2A，从“模拟人点击”到“连接智能体”，效率和体验都上了一个台阶。A2A 这个范式，从整个行业来看也是越来越成熟。




我们来简单回顾下理想同学今天已经做到了什么，以及还差什么。

已经做到的：1 第一，车机功能全部原子化。全车功能，语音可控，一句话调度。2 第二，MindGPT 大模型上车。规划理解、答案回复，能力扎实。3 第三，A2A、MCP、CUA 三种方式，接入了大量线下场景服务。停车、加油、买电影票，车上能做的事越来越多。但，还不够。坦白说，这些本质上还是把手机或屏幕上的内容搬到了车里，做了智能化。执行的还是单功能、单任务。4 这距离一个“职业司机”的标准，还差得远。职业司机是什么样的？不是你会踩油门、会打方向盘就行。而是系统级的能力——能根据路况、天气、乘客状态，把空调温度、座椅按摩、氛围灯、迎宾语、导航路线，所有这些单点能力，自主串联起来，一次性地、系统性地提供服务。比如上车主动迎宾，比如根据你的状态自动调节空间氛围。5 还有一点，职业司机最宝贵的是什么？他了解你。知道你喜欢什么温度、习惯哪条路线、什么时候想安静。这就是个性化服务。6 所以，我们认为接下来两个最重要的方向，就是：系统级智能体，加上主动个性化服务。



这一页是，理想同学系统级具身智能体架构。它和前面 Agent 2.0 有几个关键区别。

- 1 第一个区别：Agent 部署在端侧。不是云端，是直接跑在车机安卓系统里。端侧部署，意味着更低延迟、更高可用，断网了也能跑。
- 2 第二个区别：Agent 和模型分离。模型拆成两部分——端侧多模态感知模型，部署在双系统的 Linux 里，专门处理视觉等隐私数据，数据不出车；云端大模型，我们首选自研的马赫 Mind PRO，也可以接入第三方主流模型，灵活切换。
- 3 核心引擎——系统级智能体 Loop。三重安全保障：内容安全、执行安全、系统安全，层层把关，缺一不可。
- 4 模型规划上，我们做了分层规划。复杂指令进来，拆解规划，深度推理——这是慢思考；单任务进来，快速响应，直接执行——这是快反应。快慢结合，既有深度，又不拖沓。
- 5 一句话总结：端侧部署、模型分离、三重安全、分层规划——这就是系统级智能体的骨架。



来看两个真实例子，感受一下系统级智能体到底能做什么。

1 第一个例子——信息类工具的串联。用户一个复杂需求进来，系统级智能体同时调了 web_search 查航班和航站楼信息，搜了地图 UGC 推理出素食餐厅，再调路径规划和导航——多个工具自主串联，一气呵成。这还只是信息类的调度。**2** 第二个例子——更有意思，车身硬件的联动。用户说"给宝宝哄睡"。系统级智能体不是只调一个设备，而是遮阳帘、灯光、音乐、空调、音量、主动悬架，六七个设备同时联动，一秒营造出温馨的哄睡氛围。这才是真正的"具身"——车子不只是听懂你，是全身都在响应你。**3** 从信息到车身，从软件到硬件，系统级智能体正在把全车变成一个完整的汽车机器人。



具身智能体里非常核心的一块是记忆。

1 理想同学的「全信息记忆」，三层架构：应用层、能力层、数据层。

在数据层。。

在能力层。。

在应用层。。

核心理念就一句话：记忆也是效率。每一次感知，都沉淀为可调用的上下文。让交互少一些重复，让主动服务有据可依。

2 四个价值，我快速过一下：3 第一，减少重复确认。用户说"去公司总部"，每次都去 A 区，系统记住，下次不再追问。4 第二，更快理解意图。"导航去奶奶家"——系统已经知道奶奶家在望京花园，直接规划路线，不用反问。5 第三，更快执行。这是记忆效率的最高形态——把反复出现的多步操作，比如"回家"场景里的导航、空调、座椅、按摩，沉淀为程序记忆。下次遇到同样场景，一次性拉起，跳过推理，直接执行。System 2 下沉为 System 1。6 第四，主动服务有据可依。系统知道用户每周五下班去健身房，周五下午就会主动提示导航。主动不是猜，是记忆在说话。



- 1（开始播放）具身智能体要独立完成任务，首先得“看见”、“听见”、“感受到”。感知是第一步，也是最关键的一步。端侧模型的重点是，感知能力，为啥感知放端侧？两个硬约束：1.舱内视觉、语音属高隐私数据，不能出车；2.具身场景延迟敏感，所以感知只能是端侧原生。
- 2（播放完）这是我们自研的端侧大模型马赫 Mind-Edge 跑出来的真实场景。视觉感知、舱内外语音感知、交互——全部在端侧闭环。数据不出车，响应不等待，隐私不妥协。



具身智能体的能力还会继续外延。现在，具身智能体服务的是车里的人。迎宾、陪伴、车控、导航、娱乐——这是今天已经做到的。下一步，它开始服务"任务"本身。在清晰授权和安全策略下，充电、洗车、泊车、取送物、保养——这些任务，车可以自主完成，人只需要确认。从响应指令到自主服务，从被动响应到主动执行。背后靠什么？

- 1 系统级智能体的持续能力升级
- 2 真实数据 + 仿真 + 评估 + 模型迭代，四个飞轮持续转动，把能力边界一圈一圈往外推。
- 3 在具身智能体的考核指标上，除了任务完成外，我们也期望释放人类精力作为其中一个考核。



期待与行业同行者一起，走进具身智能的时代

期待与行业同行者一起，走进具身智能的时代

谢谢观看

谢谢大家